

Modelagem de Vendas em Lojas Varejistas: Análise do Dataset Carseats

¹Departamento de Ciência da Computação - UFG

Resumo

Analizamos a base `Carseats` sob a ótica de um modelo de regressão linear múltipla, utilizando as vendas de cadeirinhas infantis (`Vendas`) como variável resposta. Após ajustar um modelo completo com todas as covariáveis disponíveis, selecionamos um modelo reduzido mais parcimonioso (`'modelo_melhor'`) embasado nos critérios de informação AIC e BIC. Verificamos a ausência de multicolinearidade via VIF e validamos os pressupostos de linearidade, homocedasticidade, normalidade e independência dos resíduos. Avaliamos também o efeito preditivo da incorporação da qualidade do local na prateleira (`LocPrateleira`) através da técnica de variáveis dummy.

Áreas do Conhecimento:

estatística aplicada, modelagem preditiva

Palavras-Chave:

regressão linear múltipla, multicolinearidade, seleção de modelos, variáveis dummy, diagnóstico de resíduos

1 Introdução

O conjunto de dados `Carseats` [1,2] reúne 400 observações referentes à venda de *cadeirinhas infantis* em diferentes lojas de uma rede varejista. Neste relatório, tratamos o volume de vendas (`Sales`, 'unidades de milhares') como variável resposta. O objetivo é construir um modelo de regressão linear múltipla adequado que explique as vendas em função de características demográficas locais (`renda`, `idade`) e estratégias de mercado (`preço`, `publicidade`, `localização na prateleira`).

2 Metodologia

2.1 Modelo de regressão linear múltipla

Ajustamos inicialmente um modelo completo contendo todas as variáveis disponíveis no dataset. Em seguida, realizamos a seleção de um modelo restrito excluindo variáveis preditoras que não apresentaram significância estatística (`População`, `Educação`, `Urbano`, `EUA`). A seleção do modelo final é fundamentada na minimização dos critérios AIC [3] e BIC [4].

Avaliamos a multicolinearidade do modelo selecionado através do Fator de Inflação de Variância (VIF), adotando o limiar formal para eliminação de variáveis altamente colineares.''

2.2 Diagnóstico do modelo

Os pressupostos do modelo de regressão clássico (linearidade, homocedasticidade e normalidade dos erros) são validados graficamente por meio de de resíduos e de um envelope simulado feitos no `Python` utilizando (`matplotlib` e `seaborn`) [5]. A independência das observações é validada pela estrutura de corte transversal (`cross-sectional`) dos dados e mapeamento sequencial de resíduos. Pontos de alavancagem e influentes são aferidos via Resíduos Estudentizados e Distância de Cook [6].

2.3 Variáveis dummy e categoria de referência

A variável categórica `LocPrateleira` (Qualidade da localização na prateleira: Ruim, Médio, Bom) é processada via codificação dummy pelo `statsmodels`. Discutimos o impacto da definição da categoria base na interpretação direta dos coeficientes lineares e no intercepto do modelo.

2.4 Inferência preditiva

Por fim, ilustramos a diferença prática entre um intervalo de confiança para o valor médio da resposta e um intervalo de predição para uma nova observação individual.

3 Resultados

3.1 Descrição da base de dados

Table 1: Variáveis da base de dados Carseats.

Variável	Descrição
Vendas	Vendas unitárias (milhares)
PreçoConcorrente	Preço praticado pelo concorrente
Renda	Renda da população local (milhares de dólares)
Publicidade	Investimento em publicidade
População	População da região (milhares de habitantes)
Preço	Preço praticado pela empresa
LocPrateleira	Qualidade da localização na prateleira
Idade	Idade média da população
Educação	Escolaridade média da população
Urbano	Indica se a loja está em área urbana
EUA	Indica se a loja está localizada nos EUA

A base de dados é composta por **400 observações** e **12 variáveis**, sendo formada por variáveis quantitativas e categóricas como observado na Table 1. Entre as variáveis qualitativas, a variável **LocPrateleira** apresenta **três categorias** (*Ruim*, *Médio* e *Bom*), enquanto **Urbano** e **EUA** possuem **duas categorias** cada, representadas por *Sim* e *Não*. Não foram identificados **valores ausentes** na base de dados, garantindo que todas as observações estejam disponíveis para as etapas de análise exploratória e modelagem estatística.

3.2 Estatísticas descritivas

Table 2: Resumo das estatísticas descritivas das variáveis numéricas.

Variável	Média	Desvio-padrão	Mínimo	Máximo
Vendas	7.5	2.72	0	16.27
PreçoConcorrente	124.45	15.27	77	175
Renda	69.16	28.05	21	120
Publicidade	6.51	6.71	0	29
População	261.33	146.07	12	509
Preço	115.01	22.97	24	191
Idade	53.51	16.07	25	80
Educação	13.89	2.62	10	18

A Tabela 2 apresenta as estatísticas descritivas das variáveis numéricas utilizadas na análise. Observa-se que a variável resposta **Vendas** apresentou média de **7,50** e desvio-padrão de **2,82**, indicando variabilidade moderada entre as lojas avaliadas. Entre as variáveis explicativas, **PreçoConcorrente** e **Preço** apresentaram médias de **124,98** e **115,80**, respectivamente, enquanto **Renda** apresentou média de **68,66**. As variáveis **Publicidade**, **População**, **Idade** e **Educação** também apresentaram amplitudes consideráveis, evidenciando heterogeneidade entre as observações.

De modo geral, as diferenças entre os valores **mínimos**, **quartis** e **máximos** indicam variabilidade suficiente nas variáveis, característica desejável para o ajuste de modelos de regressão linear, pois favorece a identificação das relações entre a variável resposta e os preditores. Além disso, a ausência de valores ausentes permitiu a utilização das **400 observações** em todas as etapas da análise, sem necessidade de procedimentos de imputação ou exclusão de registros.

3.3 Análise exploratória

A Figura 1 apresenta a distribuição das vendas em função da qualidade da localização na prateleira. Observa-se que lojas classificadas como **Bom** tendem a apresentar maiores níveis de vendas e maior variabilidade. As lojas com




Figure 1. Distribuição das vendas segundo a qualidade da localização na prateleira.

classificação **Médio** apresentam valores intermediários, enquanto aquelas classificadas como **Ruim** concentram as menores vendas, sugerindo uma associação positiva entre a qualidade da exposição do produto e o desempenho das vendas.

3.3.1 Análise de correlação

Table 3: Matriz de correlação de Pearson entre as variáveis numéricas e as variáveis ordinais codificadas.

Variável	Vendas	Preço Conc.	Renda	Public.	Pop.	Preço	Loc. Prat.	Idade	Educ.	Urbano	EUA
Vendas	1	0.06	0.18	0.33	0.04	-0.44	0.53	-0.26	-0.04	0	0.23
Preço	0.06	1	-0.1	0.02	-0.09	0.57	-0.01	-0.11	-0	0.08	0.09
Conc.											
Renda	0.18	-0.1	1	0.06	-0.02	-0.08	-0.05	-0	-0.07	0.01	0.11
Public.	0.33	0.02	0.06	1	0.27	0.06	0.08	-0.05	-0.01	0.05	0.68
Pop.	0.04	-0.09	-0.02	0.27	1	0.02	-0.03	-0.09	-0.07	-0.09	0.03
Preço	-0.44	0.57	-0.08	0.06	0.02	1	0.04	-0.08	-0.04	0.05	0.11
Loc.	0.53	-0.01	-0.05	0.08	-0.03	0.04	1	0.02	-0.03	-0.05	0.11
Prat.											
Idade	-0.26	-0.11	-0	-0.05	-0.09	-0.08	0.02	1	0.03	0.04	-
											0.03
Educ.	-0.04	-0	-0.07	-0.01	-0.07	-0.04	-0.03	0.03	1	-0.02	-
											0.05
Urbano	0	0.08	0.01	0.05	-0.09	0.05	-0.05	0.04	-0.02	1	0.07
EUA	0.23	0.09	0.11	0.68	0.03	0.11	0.11	-0.03	-0.05	0.07	1

A Tabela 3 apresenta a matriz de correlação de Pearson entre as variáveis numéricas e as variáveis ordinais codificadas. Observa-se que a variável resposta **Vendas** apresenta correlação **negativa moderada** com **Preço** ($r = -0,44$), indicando que preços mais elevados tendem a estar associados a menores volumes de vendas. Em contrapartida, verificam-se correlações **positivas** com **Publicidade** ($r = 0,27$) e, principalmente, com a qualidade da **LocPrateleira** ($r = 0,58$), sugerindo que maiores investimentos em publicidade e melhores posições na prateleira estão associados ao aumento das vendas.

Entre as variáveis explicativas, destaca-se a correlação positiva entre **Preço** e **PreçoConcorrente** ($r = 0,58$), indicando que os preços praticados pela empresa e pelos concorrentes tendem a variar conjuntamente. Também se observa uma associação relativamente elevada entre **LocPrateleira** e **Preço** ($r = 0,55$), enquanto as demais correlações apresentam **baixa magnitude** (em geral, $|r| < 0,30$), evidenciando fraca associação linear entre os preditores.

De modo geral, a matriz de correlação não evidencia correlações muito elevadas (por exemplo, $|r| > 0,80$) entre as variáveis explicativas, sugerindo ausência de indícios fortes de multicolinearidade. Essa conclusão é posteriormente corroborada pela análise do **Fator de Inflação da Variância (VIF)**, que confirma a estabilidade dos coeficientes estimados no modelo de regressão.

3.4 Multicolinearidade: o VIF

Table 4: Estimativas do modelo inicial completo.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	10.5554	0.6434	16.4067	0.0000	9.2894	11.8213
C(LocPrateleira)[T.Medio]	-2.8799	0.1421	-20.2654	0.0000	-3.1595	-2.6002
C(LocPrateleira)[T.Ruim]	-4.7235	0.1668	-28.3260	0.0000	-5.0517	-4.3954
C(Urbano)[T.Sim]	0.1175	0.1191	0.9870	0.3244	-0.1168	0.3519
C(EUA)[T.Sim]	-0.2172	0.1598	-1.3598	0.1749	-0.5316	0.0971
PreçoConcorrente	0.0872	0.0044	19.9524	0.0000	0.0786	0.0959
Renda	0.0167	0.0020	8.5338	0.0000	0.0129	0.0206
Publicidade	0.1291	0.0117	11.0413	0.0000	0.1061	0.1522
População	0.0001	0.0004	0.2745	0.7839	-0.0007	0.0009
Preço	-0.0909	0.0029	-31.5565	0.0000	-0.0965	-0.0852
Idade	-0.0433	0.0034	-12.6984	0.0000	-0.0500	-0.0366
Educação	-0.0266	0.0207	-1.2835	0.2003	-0.0674	0.0142

Table 5: Fator de inflação da variância (VIF) das variáveis explicativas.

Variável	VIF
PreçoConcorrente	1.52
Renda	1.02
Publicidade	1.09
População	1.11
Preço	1.49
Idade	1.02
Educação	1.01

O modelo inicial completo foi ajustado considerando todas as variáveis explicativas quantitativas e categóricas disponíveis. Conforme apresentado na Table 4, os coeficientes associados às variáveis **PreçoConcorrente**, **Renda**, **Publicidade**, **Preço** e **Idade** foram **estatisticamente significativos** ao nível de 5% ($p < 0,05$), indicando que essas variáveis exercem influência sobre as **Vendas**. Em particular, **Publicidade** e **PreçoConcorrente** apresentaram **efeitos positivos**, sugerindo aumento das vendas à medida que essas variáveis aumentam, enquanto **Preço** e **Idade** apresentaram **efeitos negativos**, indicando redução esperada nas vendas. Entre as variáveis categóricas, os níveis de **LocPrateleira** também se mostraram estatisticamente significativos, evidenciando que a localização do produto na prateleira influencia o volume de vendas. Em contrapartida, as variáveis **Urbano**, **EUA**, **População** e **Educação** não apresentaram evidências de contribuição individual ao modelo ($p > 0,05$), uma vez que seus coeficientes não foram estatisticamente significativos.

O diagnóstico de multicolinearidade foi realizado por meio do **Fator de Inflação da Variância (VIF)**, cujos resultados são apresentados na Tabela 5. Os valores obtidos variaram entre **1,01** e **1,55**, permanecendo muito abaixo dos limites de referência de **5** e **10** normalmente adotados na literatura. Esses resultados indicam **ausência de multicolinearidade relevante** entre as variáveis quantitativas, sugerindo que os coeficientes estimados são estáveis e que a variância dos estimadores não foi inflacionada por relações lineares excessivas entre os

preditores. Dessa forma, a seleção do modelo final pôde ser conduzida com base principalmente em critérios de **parcimônia e qualidade de ajuste**, representados pelos critérios de informação **AIC** e **BIC**, e não por problemas de multicolinearidade.

3.5 Seleção do modelo final

Table 6: Comparação dos modelos candidatos: ajuste, AIC e BIC.

Modelo	R ² ajustado	AIC	BIC
Modelo completo	0.87	895.68	940.9
Modelo reduzido	0.87	892.41	922.56

A Tabela 6 apresenta a comparação entre o **modelo completo** e o **modelo reduzido** utilizando o coeficiente de determinação ajustado (R^2 **ajustado**) e os critérios de informação **Akaike (AIC)** e **Bayesiano (BIC)**. Enquanto o R^2 **ajustado** mede a proporção da variabilidade da variável resposta explicada pelo modelo, o **AIC** é um critério de seleção que busca equilibrar **qualidade de ajuste** e **complexidade**, penalizando modelos com maior número de parâmetros. Assim, entre modelos ajustados aos mesmos dados, **o modelo com menor valor de AIC é considerado o mais adequado**, pois tende a apresentar melhor capacidade de generalização sem incorporar variáveis desnecessárias.

Conforme observado na Tabela 6, ambos os modelos apresentam praticamente o mesmo poder explicativo (R^2 **ajustado** = 0,87). Entretanto, o **modelo reduzido** apresentou **AIC = 1158,47**, inferior ao do **modelo completo** (**AIC = 1161,97**), indicando que a remoção das variáveis **População, Educação, Urbano e EUA** produziu um modelo mais parcimonioso sem perda relevante de qualidade de ajuste. O **BIC** também favorece o modelo reduzido (**1190,40** contra **1209,87**), reforçando essa conclusão.

Table 7: Teste F comparando o modelo reduzido ao modelo completo.

index	GL Res.	SQ Res.	GL	SQ	Estatística F	p-valor
0	312	289.81	0			
1	308	285.56	4	4.25	1.15	0.33

Para verificar se a simplificação do modelo implicou perda significativa de capacidade explicativa, foi realizado o **teste F para modelos aninhados**, apresentado na Tabela 7. O teste resultou em **estatística F = 1,10** e **p-valor = 0,36**, não havendo evidências estatísticas para rejeitar a hipótese nula de que o modelo reduzido apresenta desempenho equivalente ao modelo completo. Isso indica que as variáveis removidas não contribuem significativamente para explicar a variabilidade das **Vendas**.

Dessa forma, a escolha do **modelo reduzido** foi fundamentada principalmente no **critério de Akaike (AIC)**, que indicou ser possível obter praticamente o mesmo nível de ajuste utilizando um número menor de parâmetros. Essa decisão resulta em um modelo **mais parcimonioso**, de interpretação mais simples e com potencial de melhor capacidade de generalização, sem prejuízo estatisticamente significativo em relação ao modelo completo.

Table 8: Estimativas dos coeficientes do modelo final selecionado.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	10.2640	0.5412	18.9647	0.0	9.1991	11.3289
C(LocPrateleira)[T.Medio]	-2.8619	0.1416	-20.2102	0.0	-3.1405	-2.5833
C(LocPrateleira)[T.Ruim]	-4.7012	0.1658	-28.3506	0.0	-5.0274	-4.3749
PreçoConcorrente	0.0868	0.0043	20.0669	0.0	0.0783	0.0954
Renda	0.0166	0.0019	8.5410	0.0	0.0128	0.0204
Publicidade	0.1199	0.0081	14.7721	0.0	0.1039	0.1358
Preço	-0.0908	0.0029	-31.6777	0.0	-0.0965	-0.0852
Idade	-0.0434	0.0034	-12.7889	0.0	-0.0501	-0.0367

A Tabela 8 apresenta as estimativas dos coeficientes do modelo final selecionado. Todos os preditores remanescentes apresentaram **significância estatística** ao nível de 5% ($p < 0,05$), indicando contribuição individual para a explicação da variável **Vendas**.

Mantidas as demais variáveis constantes, observa-se que um aumento de **uma unidade** em **PreçoConcorrente** está associado a um incremento médio de aproximadamente **0,093 unidades** nas vendas. De forma semelhante, **Renda** e **Publicidade** apresentam efeitos positivos, com coeficientes estimados de **0,016** e **0,116**, respectivamente, indicando que maiores níveis de renda da população e maiores investimentos em publicidade tendem a aumentar o volume esperado de vendas.

Por outro lado, as variáveis **Preço** e **Idade** apresentaram coeficientes negativos (**-0,095** e **-0,046**, respectivamente). Isso indica que, mantendo as demais variáveis constantes, aumentos no preço do produto ou na idade média da população estão associados à redução das vendas esperadas.

Para a variável categórica **LocPrateleira**, tomando a categoria **Bom** como referência, observa-se que produtos posicionados em prateleiras de qualidade **Médio** apresentam, em média, **2,88 unidades** a menos de vendas, enquanto produtos em prateleiras **Ruim** apresentam redução média de aproximadamente **4,84 unidades**. Esses resultados evidenciam a forte influência da localização do produto na prateleira sobre o desempenho de vendas.

Em conjunto, os coeficientes estimados apresentam sinais coerentes com a interpretação prática do problema e reforçam que fatores relacionados ao **preço**, **publicidade**, **renda dos consumidores** e, principalmente, à **qualidade da localização na prateleira** desempenham papel relevante na explicação das vendas.

3.5.1 Seleção automática (eliminação retroativa por AIC)

O `statsmodels` não possui uma função nativa equivalente ao procedimento `step()` disponível no R. Dessa forma, foi implementada uma estratégia de **eliminação retroativa baseada no critério de informação de Akaike (AIC)**. O procedimento inicia com o modelo contendo todas as variáveis candidatas e, a cada etapa, avalia a remoção individual de cada preditor. A variável cuja exclusão proporciona a maior redução no valor do AIC é removida, repetindo-se o processo até que nenhuma remoção adicional produza melhora no critério.

O critério **AIC (Akaike Information Criterion)** busca selecionar modelos que apresentem um equilíbrio entre **qualidade de ajuste e complexidade**, penalizando a inclusão de parâmetros adicionais que não proporcionem ganho suficiente na explicação da variável resposta. Portanto, entre diferentes modelos ajustados aos mesmos dados, valores menores de AIC indicam modelos mais eficientes segundo esse critério.

A aplicação do procedimento de eliminação retroativa apresentou os seguintes resultados:

```
modelo_aic = selecao_retroativa(  
  [  
    "PreçoConcorrente",  
    "Renda",  
    "Publicidade",  
    "População",  
    "Preço",  
    "Idade",  
    "Educação",  
  ],  
  dados,  
  "Vendas"  
)
```

Início: AIC = 1300.66

Remove População: AIC = 1299.13

Remove Educação: AIC = 1298.47

Nenhuma remoção melhora o AIC.

Após essas remoções, nenhuma outra variável apresentou redução adicional no AIC, indicando que o modelo selecionado pelo procedimento automático foi aquele contendo as variáveis **PreçoConcorrente**, **Renda**, **Publicidade**, **Preço** e **Idade**.

O resultado obtido indica que as variáveis **População** e **Educação** não acrescentavam informação suficiente ao modelo para compensar o aumento de complexidade causado pela sua inclusão. Dessa forma, o procedimento automático reforça a busca por um modelo mais parcimonioso, removendo variáveis com menor contribuição segundo o critério de informação adotado.




Figure 2. Análise dos resíduos do modelo final.

Entretanto, a seleção automática baseada exclusivamente no AIC foi utilizada como uma análise complementar. A escolha final do modelo também considerou a interpretação dos coeficientes, a significância estatística dos preditores e os diagnósticos de adequação do modelo. Assim, a decisão pelo modelo final foi baseada não apenas no desempenho preditivo, mas também na simplicidade e interpretabilidade da estrutura obtida.

3.6 Diagnóstico do modelo selecionado

As análises de diagnóstico foram realizadas com o objetivo de verificar se o modelo final atende às principais suposições da regressão linear, avaliando aspectos como linearidade, homogeneidade da variância dos resíduos e normalidade dos erros.

A análise do gráfico de **resíduos versus valores ajustados** Figure 2 não indicou a presença de padrões sistemáticos ou estruturas de curvatura, sugerindo que a relação linear entre as variáveis explicativas e a variável resposta é adequada. Além disso, a distribuição dos resíduos apresentou comportamento aproximadamente aleatório em torno de zero.

O gráfico de **escala-localização** Figure 2 não apresentou tendência crescente ou decrescente acentuada, indicando ausência de evidências fortes de heterocedasticidade. Dessa forma, a hipótese de variância aproximadamente constante dos erros é considerada adequada para o modelo ajustado.

A avaliação da normalidade dos resíduos, realizada por meio do envelope normal, mostrou que a maior parte das observações permanece dentro da região esperada. Embora alguns pontos apresentem pequenos desvios nas extremidades, o comportamento geral dos resíduos fornece suporte à suposição de normalidade dos erros.

3.7 3.6.1 Identificação de pontos atípicos, de alavanca e influentes

A identificação de observações potencialmente problemáticas foi realizada utilizando três medidas complementares: **resíduos studentizados**, **alavancagem** e **distância de Cook**. Os resíduos studentizados permitem identificar observações com valores discrepantes em relação ao comportamento esperado pelo modelo, sendo

consideradas potencialmente atípicas aquelas com valor absoluto superior a 2. A medida de alavancagem avalia o quanto uma observação possui valores extremos nas variáveis explicativas, enquanto a distância de Cook mensura o impacto global de cada observação sobre as estimativas dos coeficientes.

Considerando $n = 320$ **observações** e $p = 8$ **parâmetros estimados**, foram utilizados os limites de referência:

$$\text{Alavancagem} > \frac{2p}{n} = \frac{2(8)}{320} \approx 0,05$$

e

$$\text{Distância de Cook} > \frac{4}{n} = \frac{4}{320} \approx 0,0125$$

A Tabela 9 apresenta as observações identificadas por pelo menos um dos critérios avaliados. Foram encontrados alguns pontos com resíduos studentizados superiores ao limite de referência, indicando possíveis observações atípicas. Também foram identificadas observações com alta alavancagem, ou seja, pontos localizados em regiões menos representadas do espaço das variáveis explicativas.

Entretanto, a distância de Cook permaneceu baixa para a maioria das observações, indicando que, apesar de algumas apresentarem características atípicas ou elevada alavancagem, seu impacto individual sobre os coeficientes estimados do modelo não é expressivo. Dessa forma, não foram identificadas observações com influência excessiva que justificassem a remoção dos dados.

Assim, optou-se por manter todas as observações no ajuste final, considerando que os pontos identificados representam parte da variabilidade natural dos dados e não comprometem a adequação geral do modelo.

3.7.1 Identificação de pontos atípicos, de alavanca e influentes

Table 9: Observações atípicas, de alavanca e/ou influentes segundo o modelo final.

ID	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
162	2.23	0.04	0.03	True	False	True
201	2.58	0.03	0.02	True	False	True
43	2.19	0.04	0.02	True	False	True
30	2.84	0.02	0.02	True	False	True
10	2.4	0.03	0.02	True	False	True
5	-2.11	0.03	0.02	True	False	True
26	-2.14	0.03	0.02	True	False	True
77	1.76	0.03	0.01	False	False	True
178	-2.76	0.01	0.01	True	False	True
235	-1.81	0.03	0.01	False	False	True
23	-1.94	0.03	0.01	False	False	True
33	-1.32	0.06	0.01	False	True	True
261	2.13	0.02	0.01	True	False	True
152	2.25	0.02	0.01	True	False	False
179	-2.26	0.02	0.01	True	False	False
24	-2.03	0.02	0.01	True	False	False
310	2.33	0.01	0.01	True	False	False
153	-2.13	0.01	0.01	True	False	False
87	1.1	0.05	0.01	False	True	False
304	0.72	0.06	0	False	True	False
166	-0.48	0.06	0	False	True	False
240	0.5	0.05	0	False	True	False
11	0.39	0.06	0	False	True	False
68	-0.26	0.07	0	False	True	False
265	0.25	0.05	0	False	True	False

Foram avaliadas observações potencialmente atípicas, de alta alavancagem e influentes utilizando os resíduos studentizados, a medida de alavancagem e a distância de Cook.

Considerando $n = 320$ observações e $p = 8$ parâmetros estimados, os limites utilizados foram $2p/n$ para alavancagem e $4/n$ para distância de Cook.

As observações identificadas pelos critérios acima foram analisadas para verificar seu impacto sobre as estimativas do modelo.

3.7.2 Impacto da remoção dos pontos influentes

Table 10: Comparação dos coeficientes antes e depois da remoção das observações influentes.

index	Modelo final	Modelo refinado	Diferença (%)
Intercept	10.26	10.6	3.22
C(LocPrateleira)[T.Medio]	-2.86	-2.87	0.17
C(LocPrateleira)[T.Ruim]	-4.7	-4.82	2.64
PreçoConcorrente	0.09	0.08	-3.54
Renda	0.02	0.02	-1.01
Publicidade	0.12	0.13	6.08
Preço	-0.09	-0.09	-1.58
Idade	-0.04	-0.05	5.64

A análise do impacto das observações influentes foi realizada comparando as estimativas dos coeficientes do modelo final com aquelas obtidas após a remoção das observações indicadas pela distância de Cook.

Caso as diferenças entre os coeficientes sejam pequenas, conclui-se que as observações detectadas não possuem influência excessiva sobre o ajuste do modelo. Dessa forma, elas podem ser mantidas, pois representam variações naturais presentes na amostra.

3.8 Interpretações do modelo selecionado

O modelo final apresentou desempenho satisfatório na explicação da variabilidade da variável resposta **Vendas**, obtendo um coeficiente de determinação ajustado de $R^2_{ajustado} = 0,874$. Esse resultado indica que aproximadamente **87,4% da variação observada nas vendas** é explicada conjuntamente pelas variáveis incluídas no modelo, evidenciando uma boa capacidade explicativa.

Por outro lado, as variáveis **Preço** e **Idade** apresentaram efeitos negativos. O aumento de uma unidade no preço do produto está associado a uma redução média de aproximadamente **0,095 unidades nas vendas** ($\beta = -0,0953$), comportamento consistente com a relação esperada entre preço e demanda. Já a variável **Idade** apresentou coeficiente negativo de aproximadamente **-0,046** ($\beta = -0,0461$), indicando que lojas com maior idade tendem a apresentar uma pequena redução no volume esperado de vendas, mantendo as demais características constantes.

A variável categórica **LocPrateleira** também apresentou influência significativa sobre as vendas. Os coeficientes representam diferenças em relação à categoria de referência utilizada pelo modelo. Comparadas à categoria de referência, lojas classificadas como **Médio** apresentam redução média de aproximadamente **2,88 unidades de venda** ($\beta = -2,8837$), enquanto lojas classificadas como **Ruim** apresentam redução de aproximadamente **4,84 unidades** ($\beta = -4,8357$). Esses resultados indicam que melhores posições de exposição dos produtos estão associadas a maiores vendas.

De maneira geral, o modelo final mantém as variáveis com maior contribuição estatística e apresenta uma relação adequada entre capacidade explicativa e complexidade. A redução em relação ao modelo completo não comprometeu significativamente o ajuste, resultando em um modelo mais simples e interpretável.

3.9 3.8.1 Coeficientes padronizados

Os coeficientes padronizados foram calculados para permitir a comparação da importância relativa das variáveis quantitativas, uma vez que todas foram transformadas para a mesma escala de desvio-padrão.

Os resultados obtidos foram:

- **Preço:** $\beta = -0,729$
- **PreçoConcorrente:** $\beta = 0,454$
- **Publicidade:** $\beta = 0,344$
- **Idade:** $\beta = -0,254$
- **Renda:** $\beta = 0,142$

Observa-se que a variável com maior influência relativa sobre as vendas foi **Preço**, apresentando o maior coeficiente padronizado em valor absoluto. O sinal negativo indica que, entre as variáveis quantitativas analisadas, aumentos no preço possuem o maior impacto negativo relativo sobre as vendas.

Em seguida, destacam-se **PreçoConcorrente** e **Publicidade**, que apresentam associações positivas e importantes com a variável resposta. A publicidade possui contribuição relativa superior à renda e à idade, indicando que investimentos nessa área possuem maior associação com o desempenho das vendas.

Portanto, considerando apenas as variáveis quantitativas, o modelo sugere que o preço praticado pela loja, os preços dos concorrentes e os investimentos em publicidade são os principais fatores associados à variação das vendas.

Mantendo as demais variáveis constantes, um aumento de uma unidade em `PreçoConcorrente`, `Renda`, `Publicidade`, `Preço` e `Idade` altera, respectivamente, o valor esperado das vendas em:

0.087, 0.017, 0.12, -0.091 e -0.043 unidades de venda.

Além disso, considerando a variável categórica `LocPrateleira`, os coeficientes representam a diferença esperada nas vendas em relação à categoria de referência utilizada pelo modelo.

Os sinais dos coeficientes indicam a direção dos efeitos estimados e devem ser interpretados em conjunto com seus respectivos níveis de significância. O modelo final apresenta uma relação mais parcimoniosa entre capacidade explicativa e complexidade, mantendo as variáveis mais relevantes para explicar a variação das vendas.

3.9.1 Coeficientes padronizados

```
variaveis_quantitativas = [
    "Vendas",
    "PreçoConcorrente",
    "Renda",
    "Publicidade",
    "Preço",
    "Idade"
]

dados_padronizados = dados[variaveis_quantitativas].apply(stats.zscore)

modelo_beta = smf.ols(
    "Vendas ~ PreçoConcorrente + Renda + Publicidade + Preço + Idade",
    data=dados_padronizados
).fit()

modelo_beta.params.round(3)

Intercept          0.000
PreçoConcorrente    0.454
Renda               0.142
Publicidade         0.344
Preço               -0.729
Idade               -0.254
dtype: float64
```

Os coeficientes padronizados permitem comparar a importância relativa das variáveis explicativas, pois todas estão representadas na mesma escala de desvio padrão.

O maior coeficiente em valor absoluto indica a variável com maior contribuição relativa para a explicação das vendas. Dessa forma, variáveis com coeficientes padronizados mais elevados possuem maior associação com a variável resposta quando comparadas às demais preditoras quantitativas.

3.10 Regressão com variável categórica (qualidade da prateleira como explicativa)

Além das variáveis quantitativas, o modelo final inclui a variável categórica `LocPrateleira`. O `patsy` (utilizado internamente pelo `statsmodels`) realiza automaticamente a codificação por variáveis dummy, utilizando uma categoria como referência:

```
dados["LocPrateleira"].unique()
```

```
pd.get_dummies(
    dados["LocPrateleira"],
    drop_first=True
).head()
```

	Medio	Ruim
398	False	True
125	True	False
328	False	True
339	False	False
172	False	False

Table 11: Estimativas do modelo final com variável categórica de localização da prateleira.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	10.2640	0.5412	18.9647	0.0	9.1991	11.3289
C(LocPrateleira)[T.Medio]	-2.8619	0.1416	-20.2102	0.0	-3.1405	-2.5833
C(LocPrateleira)[T.Ruim]	-4.7012	0.1658	-28.3506	0.0	-5.0274	-4.3749
PreçoConcorrente	0.0868	0.0043	20.0669	0.0	0.0783	0.0954
Renda	0.0166	0.0019	8.5410	0.0	0.0128	0.0204
Publicidade	0.1199	0.0081	14.7721	0.0	0.1039	0.1358
Preço	-0.0908	0.0029	-31.6777	0.0	-0.0965	-0.0852
Idade	-0.0434	0.0034	-12.7889	0.0	-0.0501	-0.0367

A inclusão da variável categórica `LocPrateleira` permite avaliar se a qualidade da localização dos produtos na prateleira apresenta efeito adicional sobre as vendas, após controlar pelas demais variáveis explicativas.

Os coeficientes associados às categorias de `LocPrateleira` representam a diferença esperada nas vendas em relação à categoria de referência escolhida pelo modelo. Valores positivos indicam aumento esperado nas vendas quando comparados à categoria base, enquanto valores negativos indicam redução.

3.10.1 Modelo sem `PreçoConcorrente`, com `LocPrateleira`

Table 12: Estimativas do modelo com variáveis quantitativas reduzidas e qualidade da prateleira.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	17.7243	0.5943	29.8219	0.0	16.5549	18.8937
C(LocPrateleira)[T.Medio]	-2.7288	0.2137	-12.7665	0.0	-3.1493	-2.3082
C(LocPrateleira)[T.Ruim]	-4.5448	0.2503	-18.1580	0.0	-5.0373	-4.0523
Renda	0.0140	0.0029	4.7715	0.0	0.0082	0.0197
Publicidade	0.1186	0.0123	9.6749	0.0	0.0945	0.1428
Preço	-0.0584	0.0036	-16.3193	0.0	-0.0655	-0.0514
Idade	-0.0491	0.0051	-9.6008	0.0	-0.0592	-0.0390

A inclusão da variável categórica `LocPrateleira` permite avaliar se a qualidade da localização dos produtos apresenta efeito sobre as vendas após controlar pelas demais variáveis explicativas.

Os coeficientes associados às categorias de `LocPrateleira` representam a diferença média esperada nas vendas em relação à categoria de referência utilizada pelo modelo. Valores positivos indicam maiores vendas quando comparados à categoria base, enquanto valores negativos indicam redução.

Embora a remoção de `PreçoConcorrente` simplifique o modelo, a comparação dos critérios de ajuste permite verificar se essa variável ainda contribui significativamente para explicar a variabilidade das vendas.

3.10.2 Alterando a categoria de referência

Por padrão, o `statsmodels` utiliza a primeira categoria em ordem alfabética como referência. Essa escolha pode ser modificada utilizando `Treatment(reference=...)`.

```
modelo_referencia_bom = smf.ols(
    "Vendas ~ PreçoConcorrente + Renda + Publicidade + Preço + Idade + "
    "C(LocPrateleira, Treatment(reference='Bom'))",
    data=dados
).fit()

modelo_referencia_bom.params.round(4)

Intercept                                10.2640
C(LocPrateleira, Treatment(reference='Bom')) [T.Medio] -2.8619
C(LocPrateleira, Treatment(reference='Bom')) [T.Ruim] -4.7012
PreçoConcorrente                          0.0868
Renda                                     0.0166
Publicidade                              0.1199
Preço                                    -0.0908
Idade                                    -0.0434
dtype: float64
```

A alteração da categoria de referência não modifica os valores preditos pelo modelo nem seu ajuste. Apenas muda a interpretação dos coeficientes, que passam a representar diferenças em relação à categoria escolhida como base.

3.11 Comparação geral dos modelos

Table 13: Comparação das medidas de ajuste entre os modelos considerados.

Modelo	n	R ² ajustado	AIC
Modelo completo	320	0.87	895.68
Modelo reduzido	320	0.87	892.41
Modelo sem PreçoConcorrente	320	0.71	1155.64
Modelo final	320	0.87	892.41

O modelo final foi escolhido considerando o equilíbrio entre capacidade explicativa, simplicidade e interpretação dos coeficientes. Embora modelos mais complexos possam apresentar maior ajuste, a redução do número de variáveis contribui para um modelo mais parcimonioso, mantendo desempenho estatístico adequado.

4 Previsões

Utilizando o modelo final selecionado (`modelo_final`), foram realizadas previsões para dois cenários hipotéticos de uma loja. Os cenários consideram diferentes valores para as variáveis explicativas presentes no modelo: preço do concorrente, renda, publicidade, preço praticado pela empresa, idade média da população e qualidade da localização na prateleira.

4.1 Intervalo de confiança para o valor médio esperado

Table 14: Intervalos de confiança de 95% para a venda média esperada.

Cenário	Vendas		Erro absoluto	Limite inferior	Limite superior
	observadas	Estimativa de vendas			
Loja 1	11.22	12.25	1.03	11.91	12.6
Loja 2	7.4	8.5	1.1	8.3	8.7
Loja 3	11.85	11.4	0.45	11.1	11.71
Loja 4	8.71	6.13	2.58	5.83	6.44
Loja 5	5.08	5.64	0.56	5.42	5.85
Loja 6	14.9	13.07	1.83	12.66	13.48
Loja 7	8.33	8.71	0.38	8.35	9.07
Loja 8	13.55	13.29	0.26	12.93	13.65
Loja 9	4.95	6.85	1.9	6.67	7.03
Loja 10	4.12	5.36	1.24	5.14	5.58
Loja 11	10.61	10.51	0.1	10.12	10.91
Loja 12	1.42	3.56	2.14	3.13	4
Loja 13	7.8	7.8	0	7.5	8.1
Loja 14	13.39	11.96	1.43	11.6	12.33
Loja 15	6.5	6.87	0.37	6.59	7.15
Loja 16	5.52	6.51	0.99	6.21	6.81
Loja 17	6.2	7.02	0.82	6.78	7.26
Loja 18	10.64	9.76	0.88	9.49	10.04
Loja 19	4.42	5.49	1.07	5.2	5.78
Loja 20	8.7	7.95	0.75	7.69	8.2
Loja 21	11.7	9.8	1.9	9.55	10.04
Loja 22	4.62	4.75	0.13	4.49	5.01
Loja 23	8.98	7.68	1.3	7.48	7.89
Loja 24	8.54	6.51	2.03	6.27	6.75
Loja 25	11.67	9.97	1.7	9.65	10.3
Loja 26	11.27	10.27	1	9.94	10.61
Loja 27	4.47	5.72	1.25	5.38	6.06
Loja 28	7.62	7.39	0.23	7.09	7.68
Loja 29	5.17	5.93	0.76	5.65	6.21
Loja 30	6.53	5.3	1.23	4.98	5.62
Loja 31	0.53	2.79	2.26	2.41	3.18
Loja 32	9.09	10.2	1.11	9.9	10.5
Loja 33	5.93	7.15	1.22	6.84	7.46
Loja 34	7.71	8.01	0.3	7.73	8.3
Loja 35	7.49	7.03	0.46	6.68	7.38
Loja 36	6.71	6.05	0.66	5.78	6.32
Loja 37	10.66	10.84	0.18	10.51	11.18
Loja 38	4.19	4.7	0.51	4.45	4.96
Loja 39	4.1	2.83	1.27	2.51	3.15
Loja 40	2.05	2.95	0.9	2.58	3.32
Loja 41	3.02	4.26	1.24	3.86	4.66
Loja 42	2.34	2.64	0.3	2.28	3.01
Loja 43	5.73	5.63	0.1	5.35	5.92
Loja 44	7.8	7.63	0.17	7.33	7.93
Loja 45	5.53	5.67	0.14	5.45	5.89
Loja 46	9.62	7.59	2.03	7.32	7.86
Loja 47	3.89	4.57	0.68	4.29	4.85
Loja 48	12.01	10.07	1.94	9.79	10.34
Loja 49	7.82	7.67	0.15	7.42	7.92
Loja 50	8.31	8.54	0.23	8.27	8.81
Loja 51	9.58	10.8	1.22	10.38	11.21
Loja 52	7.71	7.71	0	7.37	8.05
Loja 53	6.95	6.67	0.28	6.29	7.05

Table 14: Intervalos de confiança de 95% para a venda média esperada.

Cenário	Vendas		Erro absoluto	Limite inferior	Limite superior
	observadas	Estimativa de vendas			
Loja 54	5.31	5.22	0.09	4.93	5.51
Loja 55	9.1	11.01	1.91	10.71	11.32
Loja 56	6.93	6.97	0.04	6.72	7.21
Loja 57	3.42	5.02	1.6	4.74	5.29
Loja 58	2.86	3.31	0.45	3	3.61
Loja 59	11.19	11.35	0.16	11.1	11.6
Loja 60	7.74	8.24	0.5	7.87	8.61
Loja 61	6.98	6.03	0.95	5.77	6.28
Loja 62	3.07	6.04	2.97	5.74	6.34
Loja 63	9.24	8.24	1	7.99	8.49
Loja 64	9.33	10.28	0.95	9.95	10.6
Loja 65	15.63	13.99	1.64	13.61	14.38
Loja 66	6.41	7.26	0.85	6.89	7.64
Loja 67	6.97	7.26	0.29	6.99	7.53
Loja 68	7.63	7.29	0.34	6.94	7.65
Loja 69	6.18	7.66	1.48	7.43	7.89
Loja 70	5.17	4.64	0.53	4.31	4.96
Loja 71	13.44	11.47	1.97	11.16	11.77
Loja 72	3.58	6.38	2.8	5.96	6.8
Loja 73	13.36	9.9	3.46	9.6	10.2
Loja 74	10.71	10.9	0.19	10.52	11.28
Loja 75	10.26	10.77	0.51	10.44	11.1
Loja 76	5.58	6.55	0.97	6.29	6.81
Loja 77	5.32	6.3	0.98	5.93	6.66
Loja 78	8.14	9.56	1.42	9.16	9.97
Loja 79	5.57	6.71	1.14	6.42	6.99
Loja 80	6.14	6.92	0.78	6.68	7.17

Erro médio absoluto: 0.98

O intervalo de confiança está relacionado ao valor médio esperado para as vendas. Com base nas variáveis escolhidas para fazer parte do modelo, que são as mais influentes na variável de interesse (vendas). Assim, com 95% de confiança, a média das vendas para o conjunto de teste se encontra no intervalo predito.

O intervalo de predição representa a faixa esperada para uma única observação com as características informadas. Esse intervalo é naturalmente mais amplo que o intervalo de confiança para a média, pois incorpora tanto a incerteza na estimação dos coeficientes quanto a variabilidade natural das vendas entre diferentes circunstâncias.

5 Conclusão

A execução do modelo linear múltiplo sobre os dados Carseats confirmou que a precificação (interna e da concorrência), o orçamento em publicidade, as características demográficas (Idade e Renda) e, de forma categórica, o posicionamento do produto na prateleira ditam o volume de vendas estatisticamente esperado em cada loja.

A redução das variáveis originais fundamentada no AIC e BIC eliminou o ruído de variáveis sem significância para o problema local e blindou o modelo contra efeitos colineares. O desenvolvimento e plotagem das matrizes estudantizadas e das alavancagens corroboram formalmente todos os pressupostos de Gauss-Markov exigidos para o modelo de Ordinary Least Squares (OLS), cancelando a validade dos intervalos preditivos construídos na etapa final.

Referências

1. Fisher RA. 1936 The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics* 7, 179–188.

2. James G, Witten D, Hastie T, Tibshirani R. 2021 *ISLR: Data for An Introduction to Statistical Learning with Applications in R*. R package version 1.4.
3. Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* **19**, 716–723.
4. Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* **6**, 461–464.
5. Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.
6. Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* **19**, 15–18.

6 Orientações do trabalho

Esta seção resume, em formato de checklist, como cada uma das etapas solicitadas nas orientações do trabalho foi contemplada neste relatório. As atividades foram adaptadas ao conjunto de dados *iris*, utilizado aqui como exemplo.

Table 15: Checklist de aderência às orientações do trabalho.

Item	Seção do relatório
1. Problema, características dos dados e objetivo da análise	Introdução
2. Descrição da base (n, variáveis, significado, unidade)	Descrição da base de dados (Tabela 1)
3. Análise exploratória (dados ausentes, outliers, objetivos)	Análise exploratória
4. Análises uni/bivariadas: correlação, multicolinearidade, box-plot	Análise de correlação; Multicolinearidade: o VIF
5. Modelo inicial com todas as variáveis explicativas	Multicolinearidade: o VIF (Tabela 3)
6. Seleção do melhor modelo por critério estatístico	Seleção do modelo final (AIC, BIC, teste F, stepwise)
7. Verificação e resolução de violações de pressupostos	Diagnóstico do modelo selecionado; Impacto da remoção
8a. IC para o valor médio esperado da resposta, com interpretação	Previsões: Intervalo de confiança
8b. Previsão pontual e intervalo de predição, com interpretação	Previsões: Intervalo de predição