

Modelagem de Vendas em Lojas Varejistas: Análise do Dataset Carseats

¹Departamento de Ciência da Computação - UFG

Resumo

Analizamos a base `Carseats` sob a ótica de um modelo de regressão linear múltipla, utilizando as vendas de cadeirinhas infantis (`Vendas`) como variável resposta. Após ajustar um modelo completo com todas as covariáveis disponíveis, selecionamos um modelo reduzido mais parcimonioso (`'modelo_melhor'`) embasado nos critérios de informação AIC e BIC. Verificamos a ausência de multicolinearidade via VIF e validamos os pressupostos de linearidade, homocedasticidade, normalidade e independência dos resíduos. Avaliamos também o efeito preditivo da incorporação da qualidade do local na prateleira (`LocPrateleira`) através da técnica de variáveis dummy.

Áreas do Conhecimento:

estatística aplicada, modelagem preditiva

Palavras-Chave:

regressão linear múltipla, multicolinearidade, seleção de modelos, variáveis dummy, diagnóstico de resíduos

1 Introdução

O conjunto de dados `Carseats` [1,2] reúne 400 observações referentes à venda de *cadeirinhas infantis* em diferentes lojas de uma rede varejista. Neste relatório, tratamos o volume de vendas (`Sales`, 'unidades de milhares') como variável resposta. O objetivo é construir um modelo de regressão linear múltipla adequado que explique as vendas em função de características demográficas locais (`renda`, `idade`) e estratégias de mercado (`preço`, `publicidade`, `localização na prateleira`).

2 Metodologia

2.1 Modelo de regressão linear múltipla

Ajustamos inicialmente um modelo completo contendo todas as variáveis disponíveis no dataset. Em seguida, realizamos a seleção de um modelo restrito excluindo variáveis preditoras que não apresentaram significância estatística (`População`, `Educação`, `Urbano`, `EUA`). A seleção do modelo final é fundamentada na minimização dos critérios AIC [3] e BIC [4].

Avaliamos a multicolinearidade do modelo selecionado através do Fator de Inflação de Variância (VIF), adotando o limiar formal para eliminação de variáveis altamente colineares.''

2.2 Diagnóstico do modelo

Os pressupostos do modelo de regressão clássico (linearidade, homocedasticidade e normalidade dos erros) são validados graficamente por meio de de resíduos e de um envelope simulado feitos no `Python` utilizando (`matplotlib` e `seaborn`) [5]. A independência das observações é validada pela estrutura de corte transversal (`cross-sectional`) dos dados e mapeamento sequencial de resíduos. Pontos de alavancagem e influentes são aferidos via Resíduos Estudentizados e Distância de Cook [6].

2.3 Variáveis dummy e categoria de referência

A variável categórica `LocPrateleira` (Qualidade da localização na prateleira: `Bad`, `Good`, `Medium`) é processada via codificação dummy pelo `statsmodels`. Discutimos o impacto da definição da categoria base na interpretação direta dos coeficientes lineares e no intercepto do modelo.

2.4 Inferência preditiva

Por fim, ilustramos a diferença prática entre um intervalo de confiança para o valor médio da resposta e um intervalo de predição para uma nova observação individual.

3 Resultados

3.1 Descrição da base de dados

Table 1: Variáveis da base de dados Carseats.

Variável	Descrição
Vendas	Vendas unitárias (milhares)
PreçoConcorrente	Preço praticado pelo concorrente
Renda	Renda da população local (milhares de dólares)
Publicidade	Investimento em publicidade
População	População da região (milhares de habitantes)
Preço	Preço praticado pela empresa
LocPrateleira	Qualidade da localização na prateleira
Idade	Idade média da população
Educação	Escolaridade média da população
Urbano	Indica se a loja está em área urbana
EUA	Indica se a loja está localizada nos EUA

A base de dados é composta por 400 observações e 12 variáveis, sendo formada por variáveis quantitativas e categóricas. Entre as variáveis qualitativas, a variável LocPrateleira apresenta três categorias: Ruim, Médio e Bom; enquanto Urbano e EUA possuem duas categorias cada, representadas por Yes e No. Não foram identificados valores ausentes na base, garantindo que todas as observações estejam disponíveis para as etapas de análise exploratória e modelagem estatística.

3.2 Qualidade dos dados

Table 2: Resumo da qualidade da base de dados.

Observações	Variáveis	Duplicatas	Observações com NA	Valores ausentes	LocPrateleira diferentes	Urbano diferentes	EUA diferentes
400	12	0	0	0	3	2	2

3.3 Estatísticas descritivas


Table 3: Estatísticas descritivas das variáveis numéricas.

Variável	n	Média	Desvio-padrão	Mínimo	1º Quartil	Mediana	3º Quartil	Máximo
Vendas	400	7.5	2.82	0	5.39	7.49	9.32	16.27
PreçoConcorrente	400	124.98	15.33	77	115	125	135	175
Renda	400	68.66	27.99	21	42.75	69	91	120
Publicidade	400	6.64	6.65	0	0	5	12	29
População	400	264.84	147.38	10	139	272	398.5	509
Preço	400	115.8	23.68	24	100	117	131	191
Idade	400	53.32	16.2	25	39.75	54.5	66	80
Educação	400	13.9	2.62	10	12	14	16	18

3.4 Análise exploratória

/tmp/ipykernel_254093/4192142331.py:28: FutureWarning:

Table 4. Resumo das estatísticas descritivas das variáveis numéricas.



Passing 'palette' without assigning 'hue' is deprecated and will be removed in v0.14.0. Assign the

```
sns.boxplot (
```

A Figura ?@fig-boxplot-prateleira apresenta a distribuição das vendas em função da qualidade da localização na prateleira. Observa-se que lojas classificadas como **Good** tendem a apresentar maiores níveis de vendas e maior variabilidade. As lojas com classificação **Medium** apresentam valores intermediários, enquanto aquelas classificadas como **Bad** concentram as menores vendas, sugerindo uma associação positiva entre a qualidade da exposição do produto e o desempenho das vendas.

3.4.1 Análise de correlação

Table 5: Matriz de correlação de Pearson entre as variáveis numéricas.

Variável	Vendas	PreçoConcorrente	Renda	Publicidade	População	Preço	Idade	Educação
Vendas	1	0.06	0.15	0.27	0.05	-0.44	-0.23	-0.05
PreçoConcorrente	0.06	1	-0.08	-0.02	-0.09	0.58	-0.1	0.03
Renda	0.15	-0.08	1	0.06	-0.01	-0.06	-0	-0.06
Publicidade	0.27	-0.02	0.06	1	0.27	0.04	-0	-0.03
População	0.05	-0.09	-0.01	0.27	1	-0.01	-0.04	-0.11
Preço	-0.44	0.58	-0.06	0.04	-0.01	1	-0.1	0.01
Idade	-0.23	-0.1	-0	-0	-0.04	-0.1	1	0.01
Educação	-0.05	0.03	-0.06	-0.03	-0.11	0.01	0.01	1

A Figura ?@fig-correlacao apresenta a matriz de correlação de Pearson entre as variáveis numéricas da base de dados. Observa-se que algumas variáveis apresentam associação linear moderada, enquanto outras possuem correlação próxima de zero. Em especial, espera-se que as Vendas estejam negativamente correlacionadas com o Preço e positivamente correlacionadas com a Publicidade e a Renda, embora a intensidade dessas relações deva ser confirmada pelos coeficientes estimados no modelo de regressão. Além disso, correlações elevadas entre variáveis explicativas podem indicar a presença de multicolinearidade, aspecto posteriormente avaliado pelo fator de inflação da variância (VIF).

3.5 Multicolinearidade: o VIF

Table 6: Estimativas do modelo inicial completo




Figure 1. Matriz de correlação de Spearman entre as variáveis numéricas e as variáveis categóricas codificadas.

Table 7: Fator de inflação da variância (VIF) das variáveis explicativas.

Variável	VIF
PreçoConcorrente	1.55
Renda	1.01
Publicidade	1.08
População	1.1
Preço	1.53
Idade	1.02
Educação	1.01

O diagnóstico de multicolinearidade foi realizado utilizando o fator de inflação da variância (VIF). Valores elevados de VIF indicam que uma variável explicativa apresenta forte relação linear com as demais variáveis do modelo, aumentando a variância dos estimadores.

A Tabela 7 apresenta os valores de VIF para as variáveis quantitativas do modelo inicial. Observa-se que todas as variáveis apresentam valores inferiores ao limite de referência de 10, indicando ausência de problemas severos de multicolinearidade. Dessa forma, as estimativas dos coeficientes permanecem estáveis quanto à presença de correlação entre os preditores.

3.6 Seleção do modelo final

Table 8: Comparação dos modelos candidatos: ajuste, AIC e BIC.

Modelo	R ² ajustado	AIC	BIC
Modelo completo	0.87	1161.97	1209.87
Modelo reduzido	0.87	1158.47	1190.4

A comparação entre os modelos foi realizada utilizando o coeficiente de determinação ajustado (R^2 ajustado), além dos critérios de informação de Akaike (AIC) e Bayesiano (BIC). Valores menores de AIC e BIC indicam modelos mais parcimoniosos, equilibrando qualidade de ajuste e complexidade.

O modelo reduzido apresenta ajuste comparável ao modelo completo, com menor complexidade estrutural. A redução do número de variáveis explicativas resulta em um modelo mais parcimonioso, mantendo capacidade explicativa semelhante segundo os critérios avaliados.

Table 9: Teste F comparando o modelo reduzido ao modelo completo.

index	GL Res.	SQ Res.	GL	SQ	Estatística F	p-valor
0	392	407.39	0			
1	388	402.83	4	4.55	1.1	0.36

O teste F foi utilizado para verificar se a remoção das variáveis presentes no modelo completo provoca perda significativa de capacidade explicativa. Caso o teste não rejeite a hipótese nula, o modelo reduzido é considerado equivalente ao modelo completo, sendo preferível devido à sua maior parcimônia.

| label: tbl-modelo-final # | tbl-cap: "Estimativas dos coeficientes do modelo final selecionado."

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	5.4752	0.5050	10.8419	0.0	4.4824	6.4681
C(LocPrateleira)[T.Good]	4.8357	0.1525	31.7096	0.0	4.5359	5.1355
C(LocPrateleira)[T.Medium]	1.9520	0.1254	15.5692	0.0	1.7055	2.1985
PreçoConcorrente	0.0926	0.0041	22.4510	0.0	0.0845	0.1007
Renda	0.0158	0.0018	8.5898	0.0	0.0122	0.0194
Publicidade	0.1159	0.0077	15.0064	0.0	0.1007	0.1311
Preço	-0.0953	0.0027	-35.6987	0.0	-0.1006	-0.0901
Idade	-0.0461	0.0032	-14.5206	0.0	-0.0524	-0.0399

3.6.1 Seleção automática (eliminação retroativa por AIC)

O `statsmodels` não possui uma função equivalente ao `step()` do R; reproduzimos a mesma lógica de eliminação retroativa manualmente, removendo a cada passo a variável cuja remoção resulta no maior ganho de AIC, e parando quando nenhuma remoção melhora o critério:

```
def selecao_retroativa(termos, dados, resposta):

    termos = termos.copy()

    modelo_atual = smf.ols(
        f"{resposta} ~ " + " + ".join(termos),
        data=dados
```

```

).fit()

print(
    f"Início: AIC = {modelo_atual.aic:.2f}"
)

while True:

    candidatos = {}

    for termo in termos:

        restantes = [
            t for t in termos
            if t != termo
        ]

        modelo = smf.ols(
            f"{resposta} ~ " + " + ".join(restantes),
            data=dados
        ).fit()

        candidatos[termo] = modelo.aic

    melhor_remocao = min(
        candidatos,
        key=candidatos.get
    )

    if candidatos[melhor_remocao] >= modelo_atual.aic:
        print(
            "Nenhuma remoção melhora o AIC."
        )
        break

    termos.remove(melhor_remocao)

    modelo_atual = smf.ols(
        f"{resposta} ~ " + " + ".join(termos),
        data=dados
    ).fit()

    print(
        f"Remove {melhor_remocao}: "
        f"AIC = {modelo_atual.aic:.2f}"
    )

    return modelo_atual

modelo_aic = selecao_retroativa(
    [
        "PreçoConcorrente",

```

```

    "Renda",
    "Publicidade",
    "População",
    "Preço",
    "Idade",
    "Educação",
],
dados,
"Vendas"
)

Início: AIC = 1668.65
Remove População: AIC = 1666.68
Remove Educação: AIC = 1665.83
Nenhuma remoção melhora o AIC.

```

O procedimento de eliminação retroativa baseado no critério AIC foi utilizado como uma estratégia de seleção automática de variáveis. O método busca encontrar um equilíbrio entre qualidade de ajuste e complexidade do modelo, penalizando modelos com excesso de parâmetros.

O modelo selecionado pelo AIC foi comparado com os modelos candidatos avaliados anteriormente. A seleção automática serviu como uma análise complementar, enquanto a decisão final considerou também a interpretação dos coeficientes e os diagnósticos de adequação do modelo.

3.7 Diagnóstico do modelo selecionado

As análises gráficas dos resíduos indicam que o modelo final apresenta comportamento compatível com as principais suposições da regressão linear. Não foram observados padrões sistemáticos no gráfico de resíduos versus valores ajustados, sugerindo adequação da relação linear.

O gráfico de escala-localização não apresenta evidências fortes de heterocedasticidade, enquanto o envelope normal mostra que a maior parte dos resíduos permanece dentro da região esperada, fornecendo suporte à hipótese de normalidade dos erros.

3.7.1 Identificação de pontos atípicos, de alavanca e influentes

Table 10: Observações atípicas, de alavanca e/ou influentes segundo o modelo final.

ID	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
357	-2.64	0.04	0.03	True	False	True
358	3.3	0.02	0.03	True	False	True
248	2.33	0.03	0.02	True	False	True
208	2.81	0.02	0.02	True	False	True
285	2.46	0.02	0.02	True	False	True
298	-2.75	0.02	0.02	True	False	True
16	2.62	0.02	0.02	True	False	True
51	-1.83	0.04	0.02	False	False	True
366	2.42	0.02	0.02	True	False	True
172	2.08	0.03	0.02	True	False	True
144	-1.98	0.03	0.02	False	False	True
93	-1.97	0.02	0.01	False	False	True
173	-1.91	0.03	0.01	False	False	True
26	1.52	0.03	0.01	False	False	True
382	1.43	0.04	0.01	False	False	True
1	2.17	0.02	0.01	True	False	False
101	-2.5	0.01	0.01	True	False	False
35	-2.09	0.01	0.01	True	False	False
376	2.22	0.01	0.01	True	False	False
76	0.94	0.05	0.01	False	True	False

Table 10: Observações atípicas, de alavanca e/ou influentes segundo o modelo final.

ID	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
166	-0.99	0.04	0.01	False	True	False
43	-0.62	0.05	0	False	True	False
175	0.61	0.04	0	False	True	False
306	0.59	0.04	0	False	True	False
311	-0.22	0.06	0	False	True	False

Foram avaliadas observações potencialmente atípicas, de alta alavancagem e influentes utilizando os resíduos studentizados, a medida de alavancagem e a distância de Cook.

Considerando $n = 400$ observações e $p = 8$ parâmetros estimados, os limites utilizados foram $2p/n$ para alavancagem e $4/n$ para distância de Cook.

As observações identificadas pelos critérios acima foram analisadas para verificar seu impacto sobre as estimativas do modelo.

3.7.2 Impacto da remoção dos pontos influentes

Table 11: Comparação dos coeficientes antes e depois da remoção das observações influentes.

index	Modelo final	Modelo refinado	Diferença (%)
Intercept	5.48	5.47	-0.08
C(LocPrateleira)[T.Good]	4.84	4.89	1.19
C(LocPrateleira)[T.Medium]	1.95	1.94	-0.66
PreçoConcorrente	0.09	0.09	-2.13
Renda	0.02	0.02	2.27
Publicidade	0.12	0.12	2.12
Preço	-0.1	-0.09	-2.08
Idade	-0.05	-0.05	1.86

A análise do impacto das observações influentes foi realizada comparando as estimativas dos coeficientes do modelo final com aquelas obtidas após a remoção das observações indicadas pela distância de Cook.

Caso as diferenças entre os coeficientes sejam pequenas, conclui-se que as observações detectadas não possuem influência excessiva sobre o ajuste do modelo. Dessa forma, elas podem ser mantidas, pois representam variações naturais presentes na amostra.

Caso ocorram alterações relevantes, recomenda-se investigar individualmente essas observações, verificando possíveis erros de coleta ou características específicas dos estabelecimentos.

3.8 Interpretações do modelo selecionado

O modelo final explica uma proporção estatisticamente significativa e relevante da variância de *Vendas* (R^2 ajustado = 0.87).

Mantendo as demais variáveis constantes, um aumento de uma unidade em *PreçoConcorrente*, *Renda*, *Publicidade*, *Preço* e *Idade* altera, respectivamente, o valor esperado das vendas em:


0.093, 0.016, 0.116, -0.095 e -0.046 unidades de venda.

Além disso, considerando a variável categórica *LocPrateleira*, os coeficientes representam a diferença esperada nas vendas em relação à categoria de referência utilizada pelo modelo.


Os sinais dos coeficientes indicam a direção dos efeitos estimados e devem ser interpretados em conjunto com seus respectivos níveis de significância. O modelo final apresenta uma relação mais parcimoniosa entre capacidade explicativa e complexidade, mantendo as variáveis mais relevantes para explicar a variação das vendas.

3.8.1 Coeficientes padronizados

```
variaveis_quantitativas = [
    "Vendas",
    "PreçoConcorrente",
```

(a) Análise dos resíduos do modelo final.



(b)

Figure 2.

```

    "Renda",
    "Publicidade",
    "Preço",
    "Idade"
]

dados_padronizados = dados[variaveis_quantitativas].apply(stats.zscore)

modelo_beta = smf.ols(
    "Vendas ~ PreçoConcorrente + Renda + Publicidade + Preço + Idade",
    data=dados_padronizados
).fit()

modelo_beta.params.round(3)

Intercept          -0.000
PreçoConcorrente    0.510
Renda               0.130
Publicidade         0.308
Preço               -0.776
Idade               -0.258
dtype: float64

```

Os coeficientes padronizados permitem comparar a importância relativa das variáveis explicativas, pois todas estão representadas na mesma escala de desvio padrão.

O maior coeficiente em valor absoluto indica a variável com maior contribuição relativa para a explicação das vendas. Dessa forma, variáveis com coeficientes padronizados mais elevados possuem maior associação com a variável resposta quando comparadas às demais preditoras quantitativas.

3.9 Regressão com variável categórica (qualidade da prateleira como explicativa)

Além das variáveis quantitativas, o modelo final inclui a variável categórica `LocPrateleira`. O `patsy` (utilizado internamente pelo `statsmodels`) realiza automaticamente a codificação por variáveis `dummy`, utilizando uma categoria como referência:

```

dados["LocPrateleira"].unique()

pd.get_dummies(
    dados["LocPrateleira"],
    drop_first=True
).head()

```

	Good	Medium
0	False	False
1	True	False
2	False	True
3	False	True
4	False	False

Table 12: Estimativas do modelo final com variável categórica de localização da prateleira.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	5.4752	0.5050	10.8419	0.0	4.4824	6.4681
C(LocPrateleira)[T.Good]	4.8357	0.1525	31.7096	0.0	4.5359	5.1355
C(LocPrateleira)[T.Medium]	1.9520	0.1254	15.5692	0.0	1.7055	2.1985

Table 12: Estimativas do modelo final com variável categórica de localização da prateleira.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
PreçoConcorrente	0.0926	0.0041	22.4510	0.0	0.0845	0.1007
Renda	0.0158	0.0018	8.5898	0.0	0.0122	0.0194
Publicidade	0.1159	0.0077	15.0064	0.0	0.1007	0.1311
Preço	-0.0953	0.0027	-35.6987	0.0	-0.1006	-0.0901
Idade	-0.0461	0.0032	-14.5206	0.0	-0.0524	-0.0399

A inclusão da variável categórica `LocPrateleira` permite avaliar se a qualidade da localização dos produtos na prateleira apresenta efeito adicional sobre as vendas, após controlar pelas demais variáveis explicativas.

Os coeficientes associados às categorias de `LocPrateleira` representam a diferença esperada nas vendas em relação à categoria de referência escolhida pelo modelo. Valores positivos indicam aumento esperado nas vendas quando comparados à categoria base, enquanto valores negativos indicam redução.

3.9.1 Modelo sem `PreçoConcorrente`, com `LocPrateleira`

Table 13: Estimativas do modelo com variáveis quantitativas reduzidas e qualidade da prateleira.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	13.4006	0.5453	24.5748	0.0	12.3285	14.4727
C(LocPrateleira)[T.Good]	4.8756	0.2303	21.1750	0.0	4.4229	5.3283
C(LocPrateleira)[T.Medium]	2.0046	0.1893	10.5905	0.0	1.6324	2.3767
Renda	0.0136	0.0028	4.8906	0.0	0.0081	0.0190
Publicidade	0.1057	0.0116	9.0761	0.0	0.0828	0.1286
Preço	-0.0606	0.0033	-18.4363	0.0	-0.0670	-0.0541
Idade	-0.0498	0.0048	-10.4015	0.0	-0.0592	-0.0404

A inclusão da variável categórica `LocPrateleira` permite avaliar se a qualidade da localização dos produtos apresenta efeito sobre as vendas após controlar pelas demais variáveis explicativas.

Os coeficientes associados às categorias de `LocPrateleira` representam a diferença média esperada nas vendas em relação à categoria de referência utilizada pelo modelo. Valores positivos indicam maiores vendas quando comparados à categoria base, enquanto valores negativos indicam redução.

Embora a remoção de `PreçoConcorrente` simplifique o modelo, a comparação dos critérios de ajuste permite verificar se essa variável ainda contribui significativamente para explicar a variabilidade das vendas.

3.9.2 Alterando a categoria de referência

Por padrão, o `statsmodels` utiliza a primeira categoria em ordem alfabética como referência. Essa escolha pode ser modificada utilizando `Treatment(reference=...)`.

```
modelo_referencia_good = smf.ols(
    "Vendas ~ PreçoConcorrente + Renda + Publicidade + Preço + Idade + "
    "C(LocPrateleira, Treatment(reference='Good'))",
    data=dados
).fit()
```

```
modelo_referencia_good.params.round(4)
```

```
Intercept                                10.3109
C(LocPrateleira, Treatment(reference='Good')) [T.Bad]    -4.8357
C(LocPrateleira, Treatment(reference='Good')) [T.Medium] -2.8837
PreçoConcorrente                                0.0926
Renda                                           0.0158
Publicidade                                    0.1159
Preço                                          -0.0953
```

Idade -0.0461
dtype: float64

A alteração da categoria de referência não modifica os valores preditos pelo modelo nem seu ajuste. Apenas muda a interpretação dos coeficientes, que passam a representar diferenças em relação à categoria escolhida como base.

3.10 Comparação geral dos modelos

Table 14: Comparação das medidas de ajuste entre os modelos considerados.

Modelo	n	R ² ajustado	AIC
Modelo completo	400	0.87	1161.97
Modelo reduzido	400	0.87	1158.47
Modelo sem PreçoConcorrente	400	0.7	1487.16
Modelo final	400	0.87	1158.47

O modelo final foi escolhido considerando o equilíbrio entre capacidade explicativa, simplicidade e interpretação dos coeficientes. Embora modelos mais complexos possam apresentar maior ajuste, a redução do número de variáveis contribui para um modelo mais parcimonioso, mantendo desempenho estatístico adequado.

4 Previsões

Utilizando o modelo final selecionado (`modelo_final`), foram realizadas previsões para dois cenários hipotéticos de uma loja. Os cenários consideram diferentes valores para as variáveis explicativas presentes no modelo: preço do concorrente, renda, publicidade, preço praticado pela empresa, idade média da população e qualidade da localização na prateleira.

4.1 Intervalo de confiança para o valor médio esperado

Table 15: Intervalos de confiança de 95% para a venda média esperada.

Cenário	Estimativa de vendas	Limite inferior	Limite superior
Loja 1	8.47	8.29	8.64
Loja 2	14.36	14.05	14.67

A interpretação desses intervalos está relacionada ao valor médio esperado das vendas para lojas com características semelhantes aos cenários definidos. Assim, com 95% de confiança, a média das vendas para lojas com essas características está contida no intervalo apresentado.

##Intervalo de predição para uma nova observação

Table 16: Intervalos de predição de 95% para uma nova observação de vendas.

Cenário	Estimativa de vendas	Limite inferior	Limite superior
Loja 1	8.47	6.46	10.48
Loja 2	14.36	12.33	16.39

O intervalo de predição representa a faixa esperada para uma única nova loja com as características informadas. Esse intervalo é naturalmente mais amplo que o intervalo de confiança para a média, pois incorpora tanto a incerteza na estimação dos coeficientes quanto a variabilidade natural das vendas entre diferentes lojas.

5 Conclusão

A execução do modelo linear múltiplo sobre os dados Carseats confirmou que a precificação (interna e da concorrência), o orçamento em publicidade, as características demográficas (Idade e Renda) e, de forma categórica, o posicionamento do produto na prateleira ditam o volume de vendas estatisticamente esperado em cada loja.

A redução das variáveis originais fundamentada no AIC e BIC eliminou o ruído de variáveis sem significância para o problema local e blindou o modelo contra efeitos colineares. O desenvolvimento e plotagem das matrizes estudentizadas e das alavancagens corroboram formalmente todos os pressupostos de Gauss-Markov exigidos para o modelo de Ordinary Least Squares (OLS), cancelando a validade dos intervalos preditivos construídos na etapa final.

Referências

1. Fisher RA. 1936 The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics* **7**, 179–188.
2. James G, Witten D, Hastie T, Tibshirani R. 2021 *ISLR: Data for An Introduction to Statistical Learning with Applications in R*. R package version 1.4.
3. Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* **19**, 716–723.
4. Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* **6**, 461–464.
5. Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.
6. Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* **19**, 15–18.

6 Orientações do trabalho

Esta seção resume, em formato de checklist, como cada uma das etapas solicitadas nas orientações do trabalho foi contemplada neste relatório. As atividades foram adaptadas ao conjunto de dados `iris`, utilizado aqui como exemplo.

Table 17: Checklist de aderência às orientações do trabalho.

Item	Seção do relatório
1. Problema, características dos dados e objetivo da análise	Introdução
2. Descrição da base (n, variáveis, significado, unidade)	Descrição da base de dados (Tabela 1)
3. Análise exploratória (dados ausentes, outliers, objetivos)	Análise exploratória
4. Análises uni/bivariadas: correlação, multicolinearidade, box-plot	Análise de correlação; Multicolinearidade: o VIF
5. Modelo inicial com todas as variáveis explicativas	Multicolinearidade: o VIF (Tabela 3)
6. Seleção do melhor modelo por critério estatístico	Seleção do modelo final (AIC, BIC, teste F, stepwise)
7. Verificação e resolução de violações de pressupostos	Diagnóstico do modelo selecionado; Impacto da remoção
8a. IC para o valor médio esperado da resposta, com interpretação	Previsões: Intervalo de confiança
8b. Previsão pontual e intervalo de predição, com interpretação	Previsões: Intervalo de predição