

Modelagem do Comprimento da Sépala em Flores do Gênero Iris

¹Departamento de Ciência da Computação - UFCG

Resumo

Analisamos a base `iris` sob a ótica de um modelo de regressão linear múltipla, utilizando o comprimento da sépala (`Sepal.Length`) como variável resposta. Após identificar multicolinearidade severa entre `Petal.Length` e `Petal.Width` via VIF, selecionamos um modelo mais parcimonioso por AIC/BIC e teste F, verificamos seus pressupostos e avaliamos o efeito de incorporar a espécie como variável explicativa qualitativa, incluindo a técnica de variáveis dummy e a escolha de categoria de referência.

Áreas do Conhecimento:

estatística aplicada, modelagem preditiva

Palavras-Chave:

regressão linear múltipla, multicolinearidade, seleção de modelos, variáveis dummy

1 Introdução

O conjunto de dados `iris` [1,2] reúne 150 observações de flores de três espécies do gênero *Iris* (*setosa*, *versicolor* e *virginica*), com quatro medidas morfológicas por flor. Neste relatório, tratamos o comprimento da sépala (`Sepal.Length`) como variável resposta e as demais medidas contínuas, além da espécie, como candidatas a variáveis explicativas, com o objetivo de construir um modelo de regressão linear múltipla parcimonioso e adequado aos dados.

2 Metodologia

2.1 Modelo de regressão linear múltipla

Ajustamos inicialmente um modelo com as três variáveis contínuas disponíveis (`Sepal.Width`, `Petal.Length` e `Petal.Width`). Como estas variáveis morfológicas tendem a ser correlacionadas entre si, avaliamos a multicolinearidade por meio do fator de inflação de variância (VIF), usando como referência o limiar informal de 10 [3]. A seleção do modelo final combina os critérios AIC [4] e BIC [5], além de testes F aninhados.

2.2 Diagnóstico do modelo

Os pressupostos de linearidade, homocedasticidade e normalidade dos erros são avaliados por meio de gráficos de resíduos e de um envelope simulado [6]. Pontos atípicos, de alavanca e influentes são identificados via resíduos estudentizados, alavancagem e distância de Cook [7].

2.3 Variáveis dummy e categoria de referência

Como `Species` é uma variável categórica com três níveis, sua inclusão no modelo é feita por codificação dummy (duas colunas indicadoras), e discutimos como a escolha da categoria de referência afeta apenas a interpretação dos coeficientes, não os valores preditos.

2.4 Inferência preditiva

Por fim, ilustramos a diferença prática entre um intervalo de confiança para o valor médio da resposta e um intervalo de predição para uma nova observação individual.

3 Resultados




Figure 1. Distribuição do comprimento da sépala por espécie.

3.1 Descrição da base de dados

Table 1: Variáveis da base de dados iris.

Variável	Descrição
Sepal.Length	Comprimento da sépala (cm)
Sepal.Width	Largura da sépala (cm)
Petal.Length	Comprimento da pétala (cm)
Petal.Width	Largura da pétala (cm)
Species	Espécie (setosa, versicolor, virginica)

A base contém $n = 150$ observações, 50 para cada uma das três espécies, sem dados ausentes.

3.2 Análise exploratória

Table 2: Estatísticas descritivas das variáveis contínuas.

	mean	std	min	max
Sepal.Length	5.84	0.83	4.3	7.9
Sepal.Width	3.06	0.44	2.0	4.4
Petal.Length	3.76	1.77	1.0	6.9
Petal.Width	1.20	0.76	0.1	2.5

A Figura 1 sugere que *virginica* tende a ter sépalas mais compridas, seguida por *versicolor* e, por último, *setosa*.

3.2.1 Análise de correlação

A variável resposta *Sepal.Length* não apresenta correlação linear relevante com *Sepal.Width* ($r \approx -0,12$), mas correlaciona-se fortemente com *Petal.Length* ($r \approx 0,87$) e *Petal.Width* ($r \approx 0,82$). Entre as próprias explicativas, *Petal.Length* e *Petal.Width* apresentam correlação muito forte ($r \approx 0,96$), o que já é um indício de multicolinearidade a ser confirmado pelo VIF.

3.2.2 Multicolinearidade: o VIF




Figure 2. Matriz de correlação de Pearson entre as variáveis morfológicas.

Table 3: Estimativas do modelo inicial (sem a espécie).

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	1.8560	0.2508	7.4010	0.0	1.3604	2.3516
Q('Sepal.Width')	0.6508	0.0666	9.7654	0.0	0.5191	0.7826
Q('Petal.Length')	0.7091	0.0567	12.5025	0.0	0.5970	0.8212
Q('Petal.Width')	-0.5565	0.1275	-4.3629	0.0	-0.8086	-0.3044

Table 4: Fator de inflação de variância (VIF) de cada variável explicativa no modelo inicial.

	VIF
Sepal.Width	1.27
Petal.Length	15.10
Petal.Width	14.23

O modelo inicial apresenta ajuste elevado (R^2 ajustado = 0.8557), mas o VIF de `Petal.Length` e `Petal.Width` (acima de 14) confirma multicolinearidade severa entre essas duas variáveis, muito acima do limiar de referência de 10. Um segundo indício é o sinal negativo do coeficiente de `Petal.Width`, contraintuitivo dado que ambas as variáveis se correlacionam positivamente com a resposta: consequência típica de multicolinearidade, que torna as estimativas individuais instáveis mesmo com o ajuste global permanecendo bom.

3.3 Seleção do modelo final

Table 5: Comparação dos modelos candidatos: ajuste, AIC e BIC.

Modelo	R ² ajustado	AIC	BIC
modelo1 (completo)	0.86	82.64	94.69
modelo2 (sem <code>Petal.Width</code>)	0.84	99.03	108.06

Table 5: Comparação dos modelos candidatos: ajuste, AIC e BIC.

Modelo	R ² ajustado	AIC	BIC
modelo3 (sem <code>Petal.Length</code>)	0.7	189.82	198.85

O modelo2 (sem `Petal.Width`) apresenta AIC e BIC menores que o modelo3, com diferença muito superior a 10 em ambos os critérios, evidência forte de que é o modelo preferível. Isto é coerente com a análise de correlação: `Petal.Width` correlaciona-se um pouco menos com a resposta do que `Petal.Length`, de modo que, entre as duas variáveis colineares, é preferível manter a mais associada a `Sepal.Length`.

Table 6: Teste F comparando o modelo2 ao modelo completo (modelo1).

Modelo	GL Res.	SQ Res.	GL	SQ	Estatística F	p-valor
modelo2	147	16.3288	0			
modelo1	146	14.4454	1	1.8834	19.0352	0

O teste F rejeita a hipótese nula de que o submodelo sem `Petal.Width` explica tão bem quanto o modelo completo ($p < 0,001$), ou seja, a variável é individualmente significativa, ainda que sua presença simultânea com `Petal.Length` cause o problema de multicolinearidade discutido acima.

3.3.1 Seleção automática (eliminação retroativa por AIC)

O `statsmodels` não possui uma função equivalente ao `step()` do R; reproduzimos a mesma lógica de eliminação retroativa manualmente, removendo a cada passo a variável cuja remoção resulta no maior ganho de AIC, e parando quando nenhuma remoção melhora o critério:

```
def selecao_retroativa(formula_completa, dados, resposta):
    termos = formula_completa
    modelo_atual = smf.ols(f"Q('{resposta}') ~ " + " + ".join(f"Q('{t}')" for t in termos),
                           data=dados).fit()
    print(f"Início: AIC = {modelo_atual.aic:.2f} | termos: {termos}")
    while True:
        aics = {}
        for termo in termos:
            restantes = [t for t in termos if t != termo]
            f = f"Q('{resposta}') ~ " + " + ".join(f"Q('{t}')" for t in restantes)
            aics[termo] = smf.ols(f, data=dados).fit().aic
        melhor_termo = min(aics, key=aics.get)
        if aics[melhor_termo] >= modelo_atual.aic:
            print("Nenhuma remoção melhora o AIC. Processo encerrado.")
            break
        termos = [t for t in termos if t != melhor_termo]
        modelo_atual = smf.ols(f"Q('{resposta}') ~ " + " + ".join(f"Q('{t}')" for t in termos),
                               data=dados).fit()
        print(f"- Remove {melhor_termo}: AIC = {modelo_atual.aic:.2f} | termos: {termos}")
    return modelo_atual

_ = selecao_retroativa(["Sepal.Width", "Petal.Length", "Petal.Width"], dados, "Sepal.Length")

Início: AIC = 82.64 | termos: ['Sepal.Width', 'Petal.Length', 'Petal.Width']
Nenhuma remoção melhora o AIC. Processo encerrado.
```

Assim como no procedimento `stepwise` do R, o critério puramente preditivo (AIC) não recomenda a remoção de nenhuma variável: o modelo completo já é o ótimo local por esse critério, mesmo colinear. Como o objetivo aqui inclui interpretar os efeitos individuais, optamos por seguir com o modelo2, que resolve a multicolinearidade a um custo mínimo de ajuste (Tabela 5).




Figure 3. Análise de resíduos do modelo2.

3.4 Diagnóstico do modelo selecionado

Table 7: Estimativas dos coeficientes do modelo2 (modelo selecionado).

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	2.2491	0.2480	9.0702	0.0	1.7591	2.7392
Q('Sepal.Width')	0.5955	0.0693	8.5899	0.0	0.4585	0.7325
Q('Petal.Length')	0.4719	0.0171	27.5692	0.0	0.4381	0.5057

As Figuras 3 e 4 não indicam padrões sistemáticos relevantes nos resíduos, e a grande maioria dos pontos permanece dentro da banda do envelope simulado, dando suporte às suposições de linearidade, variância constante e normalidade dos erros.

3.4.1 Identificação de pontos atípicos, de alavanca e influentes

Table 8: Observações atípicas, de alavanca e/ou influentes segundo o modelo2.

	Espécie	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
106	virginica	-2.9112	0.0178	0.0511	True	False	True
100	virginica	-2.2694	0.0275	0.0485	True	False	True
14	setosa	1.8452	0.0403	0.0477	False	True	True

Table 8: Observações atípicas, de alavanca e/ou influentes segundo o modelo2.

	Espécie	Resíduo estud.	Alavancagem	Dist. de Cook	Atípico	Alavanca	Influente
135	virginica	2.3810	0.0200	0.0387	True	False	True
118	virginica	1.9674	0.0286	0.0380	False	False	True
62	versicolor	1.6906	0.0367	0.0363	False	False	True
87	versicolor	1.8404	0.0281	0.0327	False	False	True
136	virginica	-1.8753	0.0265	0.0319	False	False	True
131	virginica	1.1417	0.0669	0.0312	False	True	True
122	virginica	1.8890	0.0254	0.0310	False	False	True
68	versicolor	1.5786	0.0341	0.0293	False	False	True
148	virginica	-1.8900	0.0240	0.0293	False	False	True
41	setosa	0.8303	0.0645	0.0158	False	True	False
84	versicolor	-2.2874	0.0079	0.0138	True	False	False
32	setosa	-0.6102	0.0456	0.0059	False	True	False
15	setosa	0.3817	0.0704	0.0037	False	True	False
60	versicolor	-0.2841	0.0577	0.0016	False	True	False
33	setosa	0.2743	0.0532	0.0014	False	True	False
109	virginica	-0.2203	0.0455	0.0008	False	True	False
117	virginica	0.0810	0.0734	0.0002	False	True	False

Com $n = 150$ observações e $p = 3$ parâmetros, o limiar de alavanca é $2p/n \approx 0,04$ e o de Cook é $4/n \approx 0,027$.

3.4.2 Impacto da remoção dos pontos influentes

Table 9: Comparação das estimativas antes e depois da remoção dos pontos influentes.

	modelo2 (completo)	modelo2 (refinado)	Diferença (%)
Intercept	2.249	2.079	-7.56
Q('Sepal.Width')	0.596	0.645	8.22
Q('Petal.Length')	0.472	0.473	0.21

As variações nos coeficientes são modestas, indicando que as observações influentes refletem variabilidade natural dos dados e não erros de medição; optamos por manter todas as observações no modelo final.

3.5 Interpretações do modelo selecionado

O modelo2 explica uma proporção estatisticamente significativa e substancial da variância de `Sepal.Length` (R^2 ajustado = 0.838). Mantendo a outra variável constante, cada centímetro adicional em `Sepal.Width` e em `Petal.Length` aumenta, respectivamente, o comprimento médio esperado da sépala em 0.596 cm e 0.472 cm. Note que ambos os efeitos são positivos e coerentes com a análise de correlação, ao contrário do que ocorria no modelo inicial com as três variáveis contínuas, confirmando que a remoção de `Petal.Width` resolveu a instabilidade causada pela multicolinearidade.

3.5.1 Coeficientes padronizados

```
padronizados = dados[["Sepal.Length", "Sepal.Width", "Petal.Length"]].apply(stats.zscore)
modelo2_beta = smf.ols("Q('Sepal.Length') ~ Q('Sepal.Width') + Q('Petal.Length') - 1",
                        data=padronizados).fit()
modelo2_beta.params

Q('Sepal.Width')      0.313464
Q('Petal.Length')     1.006054
dtype: float64
```

Os coeficientes padronizados indicam que `Petal.Length` tem peso relativo consideravelmente maior do que `Sepal.Width` na explicação do comprimento da sépala, uma vez colocadas na mesma escala.




Figure 4. Gráfico de envelope simulado do modelo2.

3.6 Regressão com variáveis dummy (a espécie como explicativa)

Até aqui, o modelo selecionado não incluiu a espécie da flor. O `patsy` (usado internamente pela API de fórmulas do `statsmodels`) codifica automaticamente uma variável categórica como variáveis dummy, tomando a primeira categoria (`setosa`) como referência:

```
dados["Species"].cat.categories
pd.get_dummies(dados["Species"], drop_first=True).head(6)
```

	versicolor	virginica
0	False	False
1	False	False
2	False	False
3	False	False
4	False	False
5	False	False

Table 10: Estimativas do modelo com `Sepal.Width`, `Petal.Length` e `Species`.

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	2.3904	0.2623	9.1143	0.0	1.8720	2.9088
Species[T.versicolor]	-0.9558	0.2152	-4.4415	0.0	-1.3811	-0.5305
Species[T.virginica]	-1.3941	0.2857	-4.8803	0.0	-1.9587	-0.8295
Q('Sepal.Width')	0.4322	0.0814	5.3105	0.0	0.2714	0.5931
Q('Petal.Length')	0.7756	0.0642	12.0729	0.0	0.6487	0.9026

Ao incluir a espécie, os coeficientes de `Species[T.versicolor]` e `Species[T.virginica]` são negativos, sugerindo (contraintuitivamente) sépalas mais curtas nessas espécies quando comparadas a igual `Petal.Length` e `Sepal.Width`. A causa, novamente, é a multicolinearidade: `Petal.Length` está fortemente associada à espécie, de modo que as duas variáveis competem para explicar a mesma variabilidade, distorcendo os coeficientes.

3.6.1 Modelo sem Petal.Length, com a espécie

Table 11: Estimativas do modelo com Sepal.Width e Species (sem Petal.Length).

	Coef.	Std.Err.	t	P> t	[0.025	0.975]
Intercept	2.2514	0.3698	6.0889	0.0	1.5206	2.9822
Species[T.versicolor]	1.4587	0.1121	13.0120	0.0	1.2372	1.6803
Species[T.virginica]	1.9468	0.1000	19.4653	0.0	1.7492	2.1445
Q('Sepal.Width')	0.8036	0.1063	7.5566	0.0	0.5934	1.0137

Agora os coeficientes de espécie são positivos e coerentes com a análise exploratória: mantendo `Sepal.Width` fixo, uma flor *virginica* tem, em média, sépala mais comprida que uma *setosa*, e uma *versicolor* também, em menor magnitude. Este modelo tem, no entanto, R^2 ajustado inferior ao do modelo2, evidenciando o compromisso entre poder explicativo e interpretabilidade quando há multicolinearidade entre uma variável contínua e uma categórica.

3.6.2 Alterando a categoria de referência

Por padrão, a primeira categoria em ordem alfabética (*setosa*) é a referência. Isto pode ser alterado com `Treatment(reference=...)`, por exemplo para tornar *virginica* a referência:

```
modelo6 = smf.ols(
  "Q('Sepal.Length') ~ Q('Sepal.Width') + C(Species, Treatment(reference='virginica'))",
  data=dados,
).fit()
modelo6.params
```

Intercept	4.198210
C(Species, Treatment(reference='virginica'))[T.setosa]	-1.946817
C(Species, Treatment(reference='virginica'))[T.versicolor]	-0.488074
Q('Sepal.Width')	0.803561
dtype:	float64

Os valores preditos pelo modelo não se alteram com a troca de categoria de referência, apenas a forma de interpretar os coeficientes: eles agora expressam o desvio médio de cada espécie em relação a *virginica*.

3.7 Comparação geral dos modelos

Table 12: Comparação das medidas de ajuste entre todos os modelos considerados.

Modelo	n	R ² ajustado	AIC
modelo1 (completo, sem espécie)	150	0.86	82.64
modelo2 (sem Petal.Width)	150	0.84	99.03
modelo3 (sem Petal.Length)	150	0.7	189.82
modelo4 (com espécie e Petal.Length)	150	0.86	79.57
modelo5 (com espécie, sem Petal.Length)	150	0.72	181.94

O modelo2 permanece o melhor modelo em termos de AIC e simplicidade de interpretação, sendo, portanto, o modelo utilizado na etapa de previsões a seguir.

4 Previsões

Utilizando o modelo2, apresentamos as previsões para dois conjuntos hipotéticos: x_1 , com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm; e x_2 , com largura de sépala de 3,2 cm e comprimento de pétala de 5,0 cm.

4.1 Intervalo de confiança para o valor médio esperado

Table 13: Intervalos de confiança de 95% para o comprimento médio esperado da sépala, para os dois conjuntos hipotéticos.

Larg. Sépala (cm)	Comp. Pétala (cm)	Estimativa (cm)	Limite inferior	Limite superior
2.8	1.5	4.62	4.51	4.74
3.2	5	6.51	6.44	6.59

Interpretação prática: para flores com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm, estimamos que o comprimento **médio** da sépala, entre todas as flores com estas características, esteja no intervalo acima, com 95% de confiança. O mesmo raciocínio se aplica ao segundo conjunto hipotético.

4.2 Intervalo de predição para uma nova observação

Table 14: Intervalos de predição de 95% para uma nova observação do comprimento da sépala, para os dois conjuntos hipotéticos.

Larg. Sépala (cm)	Comp. Pétala (cm)	Estimativa (cm)	Limite inferior	Limite superior
2.8	1.5	4.62	3.96	5.29
3.2	5	6.51	5.85	7.18

Interpretação prática: se observarmos **uma única nova flor** com largura de sépala de 2,8 cm e comprimento de pétala de 1,5 cm, prevemos, com 95% de confiança, que o comprimento de sua sépala estará no intervalo acima, bem mais largo que o intervalo de confiança para a média, pois soma à incerteza sobre a média a variabilidade natural entre flores individuais.

5 Conclusão

A análise exploratória confirmou forte associação entre as variáveis morfológicas das flores de Iris. O modelo inicial, com todas as variáveis contínuas, apresentou ajuste elevado, mas revelou multicolinearidade severa entre o comprimento e a largura da pétala, evidenciada tanto pelos valores de VIF quanto pelo sinal contraintuitivo do coeficiente de `Petal.Width`.

O modelo final selecionado, com largura de sépala e comprimento de pétala como variáveis explicativas, preserva grande parte do poder explicativo do modelo completo e elimina a multicolinearidade relevante. Seus pressupostos foram verificados e atendidos pela análise de resíduos e pelo gráfico de envelope simulado, e a investigação de pontos influentes mostrou que sua remoção não altera as conclusões substantivas do estudo.

Ao incorporar a espécie como variável explicativa qualitativa, observamos que sua interação com `Petal.Length` também pode distorcer a interpretação dos coeficientes, ilustrando que o cuidado com multicolinearidade se estende também a pares de variáveis contínuas e categóricas. Por fim, demonstramos que a escolha da categoria de referência de uma variável dummy afeta apenas a interpretação dos coeficientes, não os valores preditos pelo modelo, e ilustramos a distinção prática entre intervalo de confiança e intervalo de predição.

Referências

1. Fisher RA. 1936 The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics* 7, 179–188.
2. Anderson E. 1935 The Irises of the Gaspé Peninsula. *Bulletin of the American Iris Society* 59, 2–5.
3. Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.
4. Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* 19, 716–723.
5. Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* 6, 461–464.
6. Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.
7. Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* 19, 15–18.

6 Orientações do trabalho

Esta seção resume, em formato de checklist, como cada uma das etapas solicitadas nas orientações do trabalho foi contemplada neste relatório. As atividades foram adaptadas ao conjunto de dados `iris`, utilizado aqui como exemplo.

Table 15: Checklist de aderência às orientações do trabalho.

Item	Seção do relatório
1. Problema, características dos dados e objetivo da análise	Introdução
2. Descrição da base (n, variáveis, significado, unidade)	Descrição da base de dados (Tabela 1)
3. Análise exploratória (dados ausentes, outliers, objetivos)	Análise exploratória
4. Análises uni/bivariadas: correlação, multicolinearidade, box-plot	Análise de correlação; Multicolinearidade: o VIF
5. Modelo inicial com todas as variáveis explicativas	Multicolinearidade: o VIF (Tabela 3)
6. Seleção do melhor modelo por critério estatístico	Seleção do modelo final (AIC, BIC, teste F, stepwise)
7. Verificação e resolução de violações de pressupostos	Diagnóstico do modelo selecionado; Impacto da remoção
8a. IC para o valor médio esperado da resposta, com interpretação	Previsões: Intervalo de confiança
8b. Previsão pontual e intervalo de predição, com interpretação	Previsões: Intervalo de predição